DOCKER

Virtualisation vs conteneurs

- Virtualisation = partage de ressources physiques
- Hyperviseur :
  - Fine couche d'OS = Noyau léger
  - Alloue des ressources physiques
  - i.e instructions CPU, adresses RAM
  - Pour Créer des Machines Virtuelles
  - i.e des OS « invités » différents
  - Ex : VMWare, Xen, KVM, Hyper-V

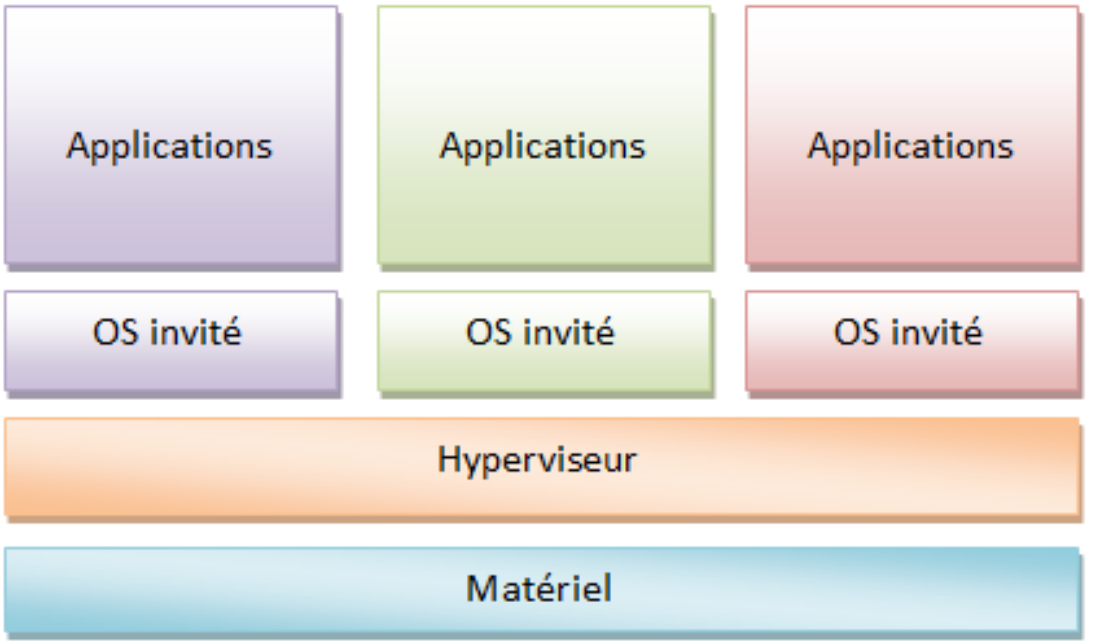

Virtualisation vs conteneurs

- Enjeux de la virtualisation
  - Meilleure adaptation aux besoins du parc informatique
  - Gain énergétique : réduction des coûts
  - Plus de flexibilité : déplacement, sauvegarde / restauration des Vms

    - PRA : Plan de Relance de l'Activité

    - RPO : « Recovery Point Objective », durée maximale d'enregistrement des données qu'il est acceptable de perdre lors d'une panne => objectif de sauvegarde

    - RTO : « recovery time objective », durée maximale d'interruption que l'on est prêt à supporter

      => objectif de restauration
  - Gain en Qualité de Service (QOS)
  - Moindres dégradations de Performances grâces au « Super - BIOS » de technos VT-x ou AMD-V

    - accès direct sur certains drivers E/S pour les os invités « para-virtualisation »

    - architectures processeur facilitant le traitements d'instructions d'un os invité étiquetées par l'hyperviseur

Virtualisation vs conteneurs

- Conteneurisation = partage des ressources logicielles du noyau de l'OS
- Logiciel de conteneurisation :
  - Créé des conteneurs
  - Isolent des processus du reste de l'OS hôte
  - Avec leur propre « vision » du système (namespaces)
  - Limités dans les ressources utilisables

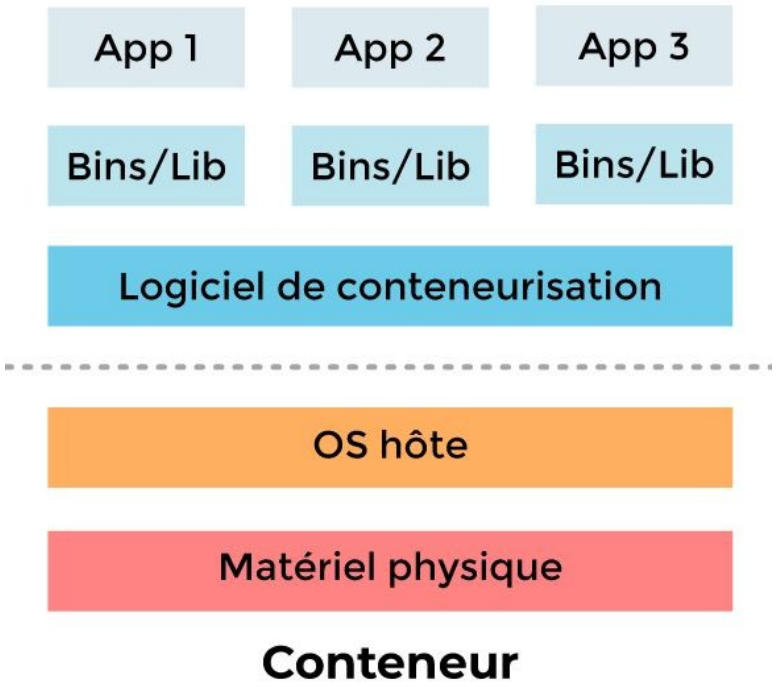

Virtualisation vs conteneurs

- Comparaison

- Les conteneurs :
  - **Plus légers**, ne comprennent que des logiciels de haut niveau (~Mo vs ~Go pour les Vms avec leur noyau et les librairies bas niveau)
  - **Plus rapides** à créer et déplacer
- Les Vms
  - **Isolation** totale des processus entre Vms, alors que le noyau de l'hôte est partagé entre conteneurs
  - **Plus dynamiques** : Les Vms sont conçues pour les interactions utilisateur, les conteneurs pour assurer les bonnes dépendances / configuration statiques du processus à isoler

- Les usages sont différents

conteneurs Linux

- Les namespaces
- Fonctionnalités du noyau linux qui assurent certains aspects de **l'isolation** des conteneurs :
  - pid : isolation des processus (1 table de process par ns)
    - (Pid, Ppid) dans le ctn != (Pid, Ppid) dans le host
  - net : isolation d'interfaces réseau (1 pile réseau par ns)
    - interfaces, addresses IP , routes, firewall
  - mount : isolation des systèmes de fichiers
    - systèmes de fichiers des images docker
  - uts : isolation du nom d'hôte
  - Ipc : « inter processus communication » entre ns
    - interdiction des cnx avec les sémaphores, segments de mémoire partagés, files
  - user : mapping des UID/GID entre l'hôte et les conteneurs host uid xxx → ctn uid 0 (par défaut)
    -

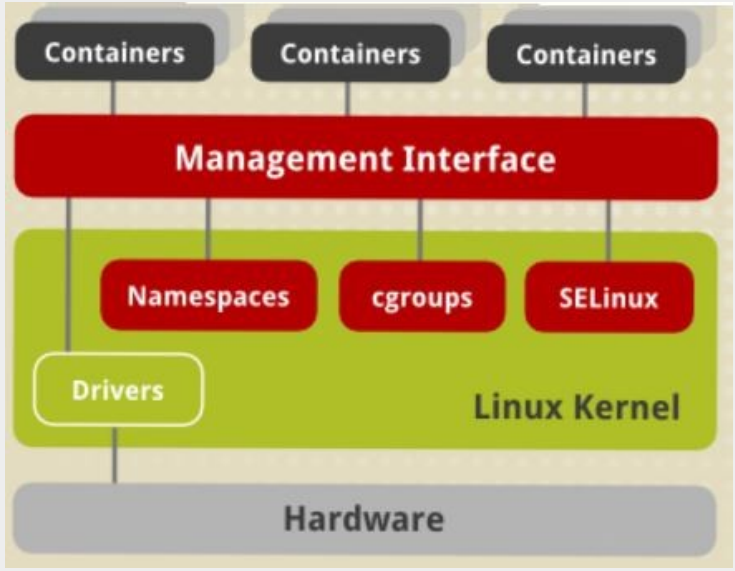

conteneurs Linux

- Les Cgroups :
- Fonctionnalités du noyau linux qui régulent l'accès aux **ressources** des processus :
  - RAM
    - limites physiques et logicielles
  - CPU
    - proportion du pool CPU
    - répartition des traitements sur les coeurs
  - I/O
  - Network
    - limitation des débits lecture / écriture

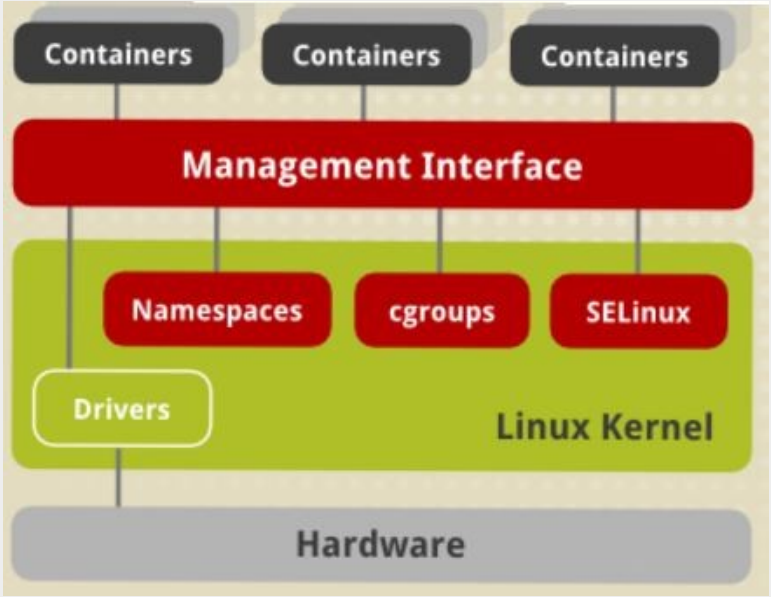

Microservices

- Architecture monolithique vs microservices :
- Une application :
  - Décomposés en **services**
  - Packagés dans des conteneur**s**
  - Disséminés dans le **cloud**
  - Qui communiquent sur le **réseau**
  - Via des **APIs**
- **Couplage faible** entre composant**s**
- Pros / cons
  - Meilleure **stabilité** des infra, meilleur **MTRS** (Mean Time to Restore Service)
  - Plus **complexe** à mettre en œuvre => utilisation **d'orchestrateurs**

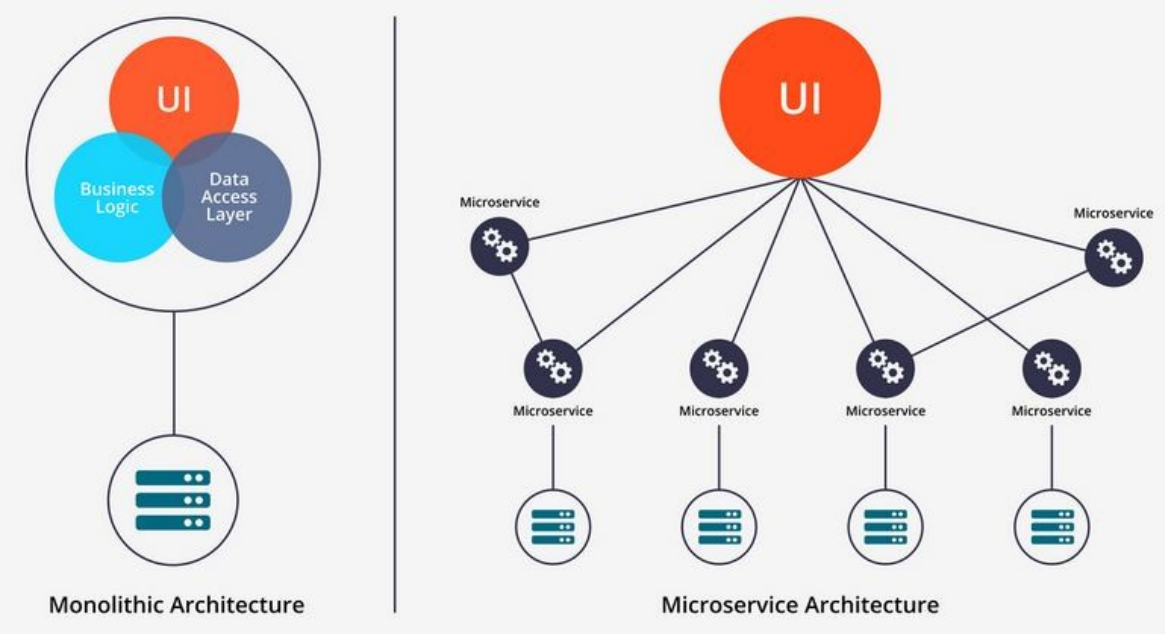

Applications Cloud Native

- Définition :
  - Cloud Native Computing Foundation
  - Application orientée Microservice
  - Dont le cycle de vie est géré par un orchestrateur
  - **Scaling horizontal** facilité
  - Aptitude au **stockage et au calcul distribués**

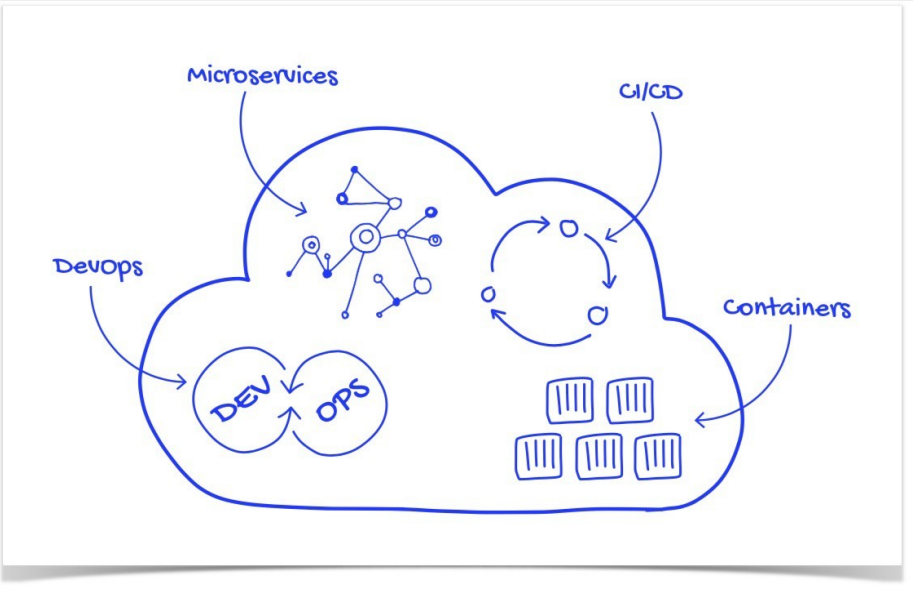

- Exemples : cncf.io
  - Kubernetes
  - Prometheus
  - Gitlab
  - ...

DOCKER

- Docker : société commerciale et technologie
- technologie :
  - Nombreuses applications prêtes l'emploi
  - Décrites par des **images** (instantanés de systèmes de fichiers)
  - Téléchargeables depuis un **registre** privé ou public (docker hub)
  - Packagées dans des conteneur**s**

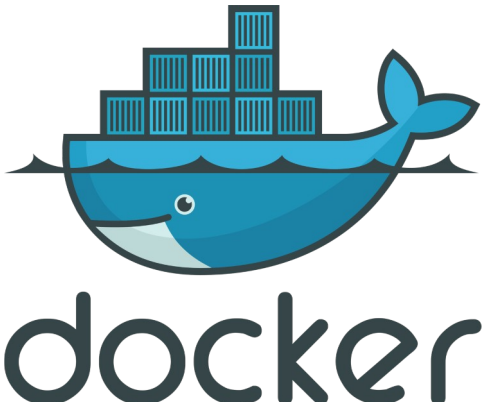

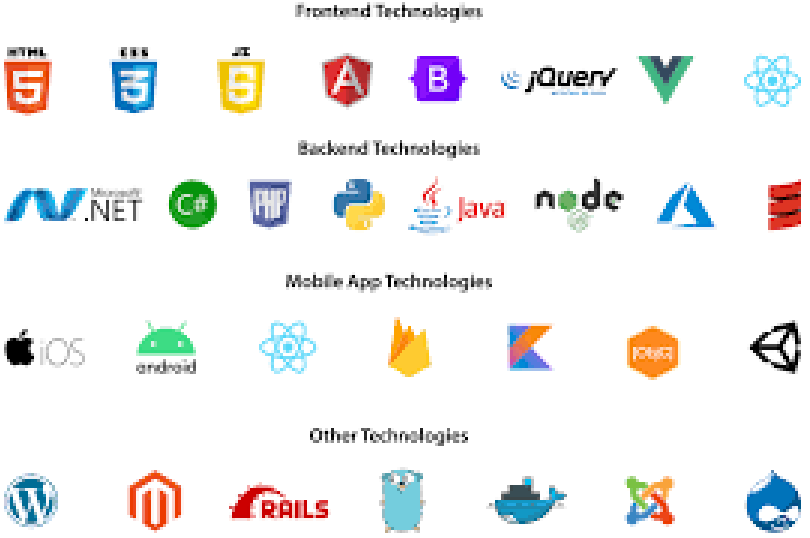

DOCKER

- Offre open source docker-ce:
  - Dsitribuée à partir de 2013
  - https://github.com/docker/docker-ce/blob/master/CHANGELOG.md
  - Concurrence
    - LXC (Linux)
    - Rkt (CoreOs – RedHat)
    - LXD (Canonical – ubuntu)

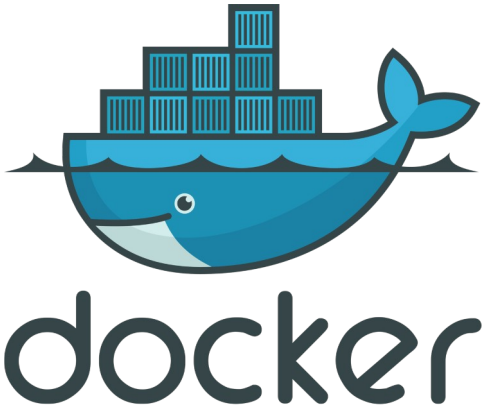

- Offre payante
  - Docker Business

DOCKER

- Une technologie client-serveur:
  - Docker Cli Client
  - Dockerd : server d'API REST
  - Briques fonctionnelles
    - conteneurs
    - images de conteneurs
    - interfaces réseau
    - Volumes de données

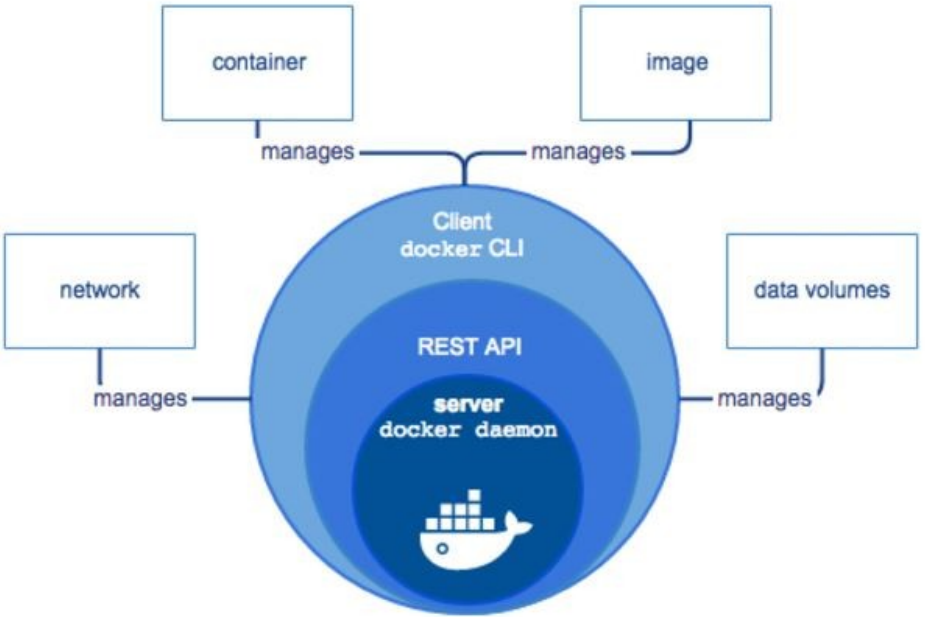

DOCKER

- Plus précisément:

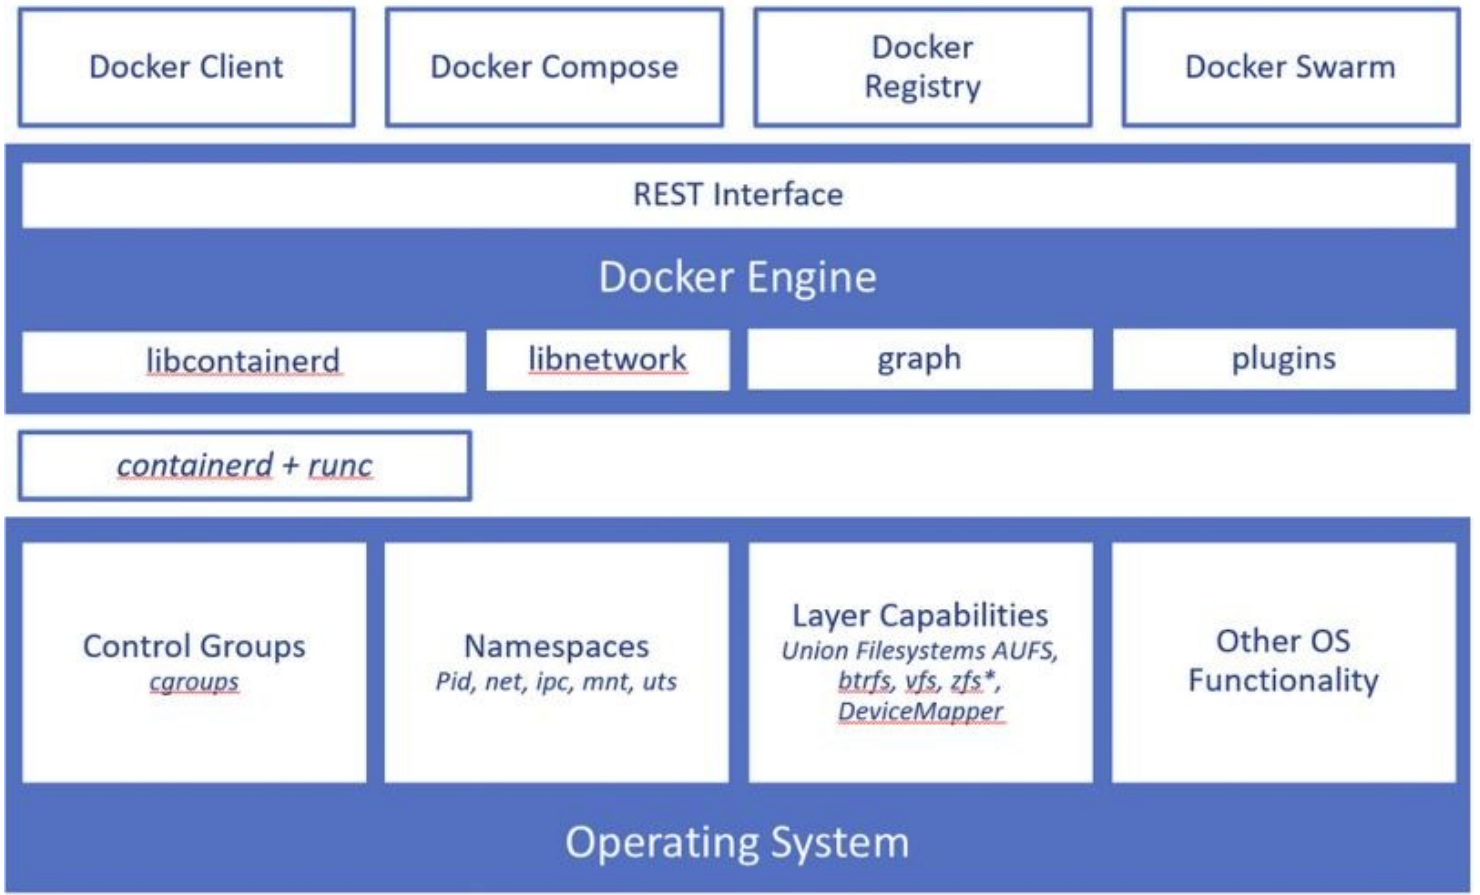

DOCKER

- responsabilités :
  - Dockerd gère
    - les call d'api et
    - le **build des images**
  - Containerd (CNCF) gère
    - les push et pull d'image (vers le **registre**)
    - le **stockage** de données
    - les couches **réseaux**
    - l'**API** de création de conteneurs
  - Runc gère
    - la manipulation de **namespaces** pour créer les conteneurs

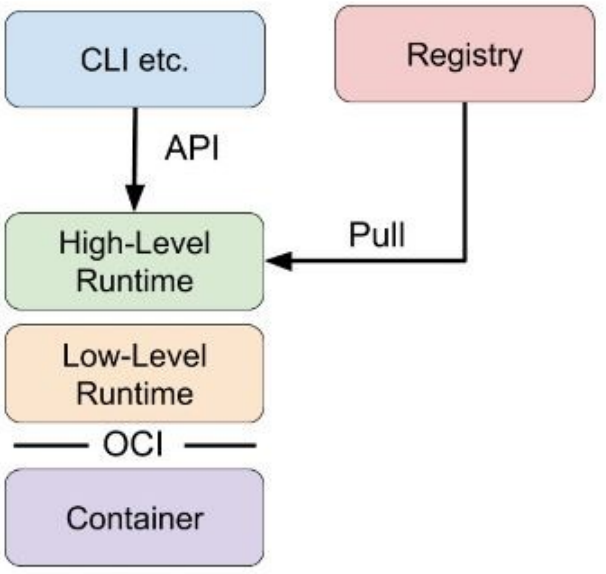

- Standards pour la conteneurisation

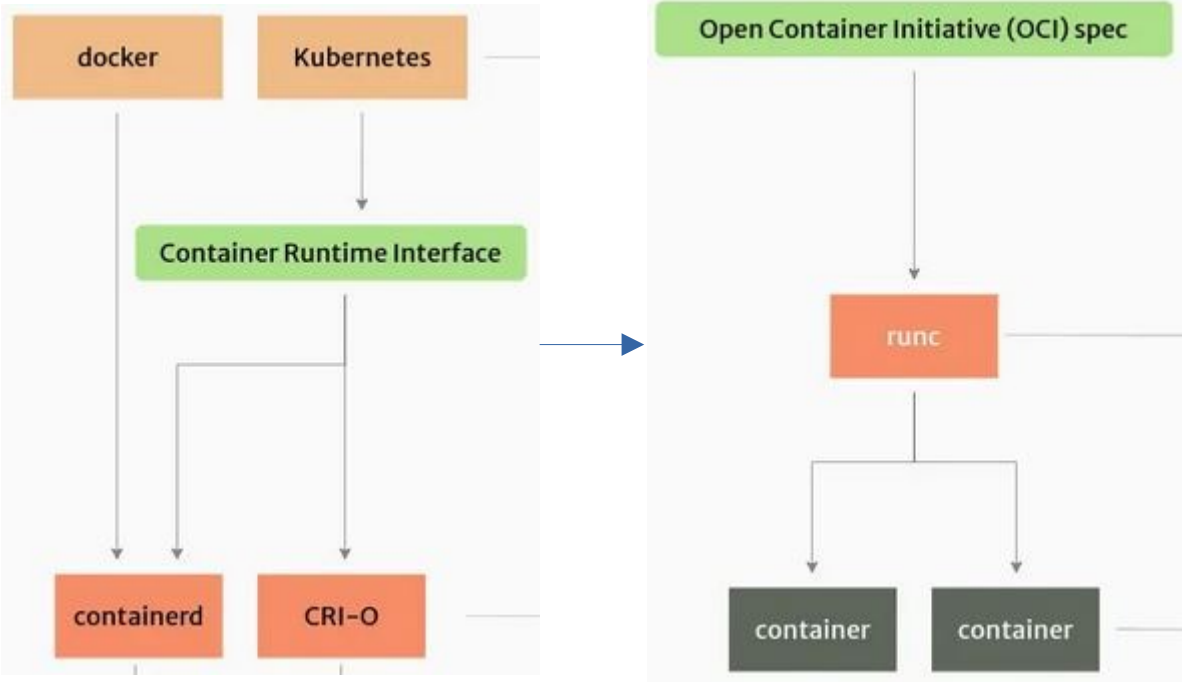

- CRI : standard pour les runtimes de Kubernetes
  Containerd est Compatible CRI

- CRI-O : runtime haut niveau de Kubernetes

- OCI : standard pour les conteneurs Linux
  Runtime bas niveau

- runc est compatible OCI

Premiers pas

- Téléchargement d'une image depuis le docker hub (hub.docker.com)
  - Une **image** décrit une technologie prête à l'emploi
  - Un **tag** précise les paquets de base et la version
  - Téléchargement : **docker pull <image>:<tag>**
  - Recherche : **docker search <image>**
  - Options courantes :
    * --filter **key=value** (stars, is-official, is-automated)
    * --format **"Go template : {{ .Name }}"**

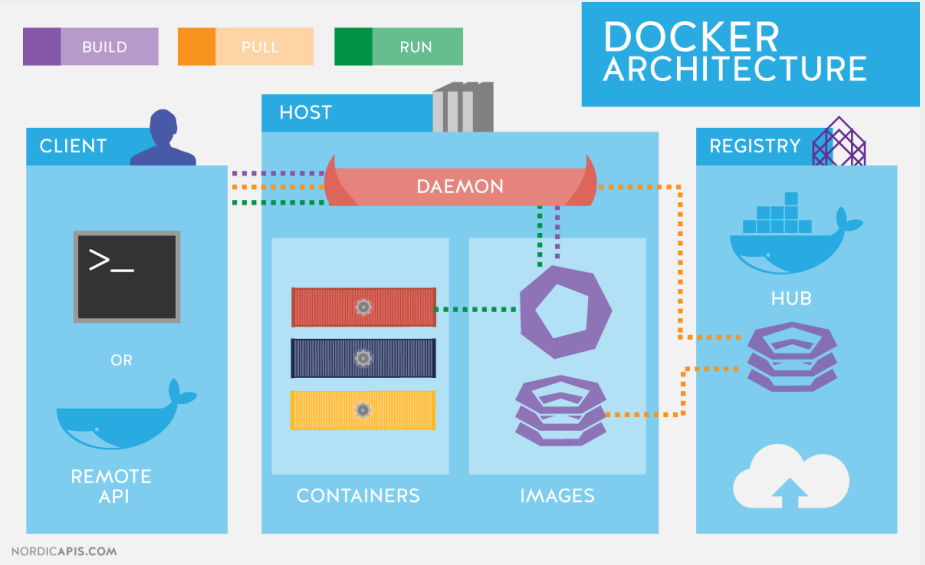

Premiers pas

- Cycle des états d'images
  - Lister : **docker image ls** ou **docker images**
  - Supprimer une image non utilisée :

    docker image rm ou **docker rmi**
  - Supprimer les images non utilisées sans tags

    docker image prune « dangling image »
  - Supprimer les images non utilisées

    docker image prune -a

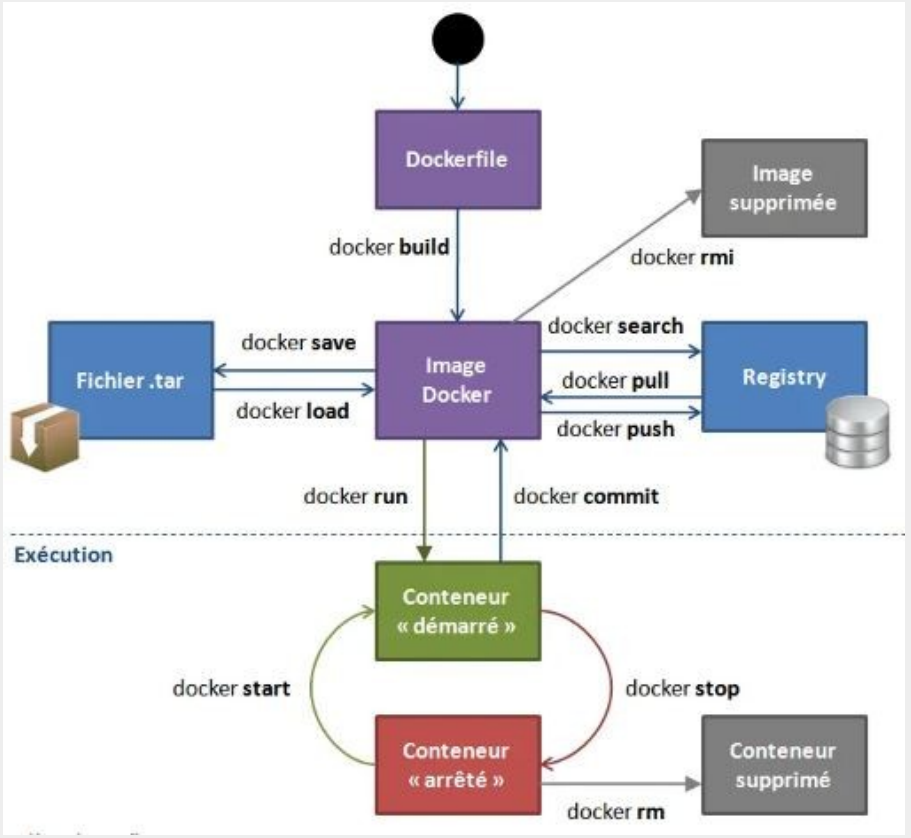

Premiers pas

- Cycle des états de conteneurs
  - Créer un conteneur : **docker create**
  - Démarrer / stopper : docker **start / stop / restart**
  - Exécuter une commande : docker **exec [cmd]**
  - **Lancer : docker run <img:tag> [cmd]**

    = create + start + exec

    - si l'image n'est pas présente, run **demande le pull**
  - Supprimer une fois stoppé : **docker rm**
  - Supprimer les conteneurs stoppés

    docker container prune [-f | --force]

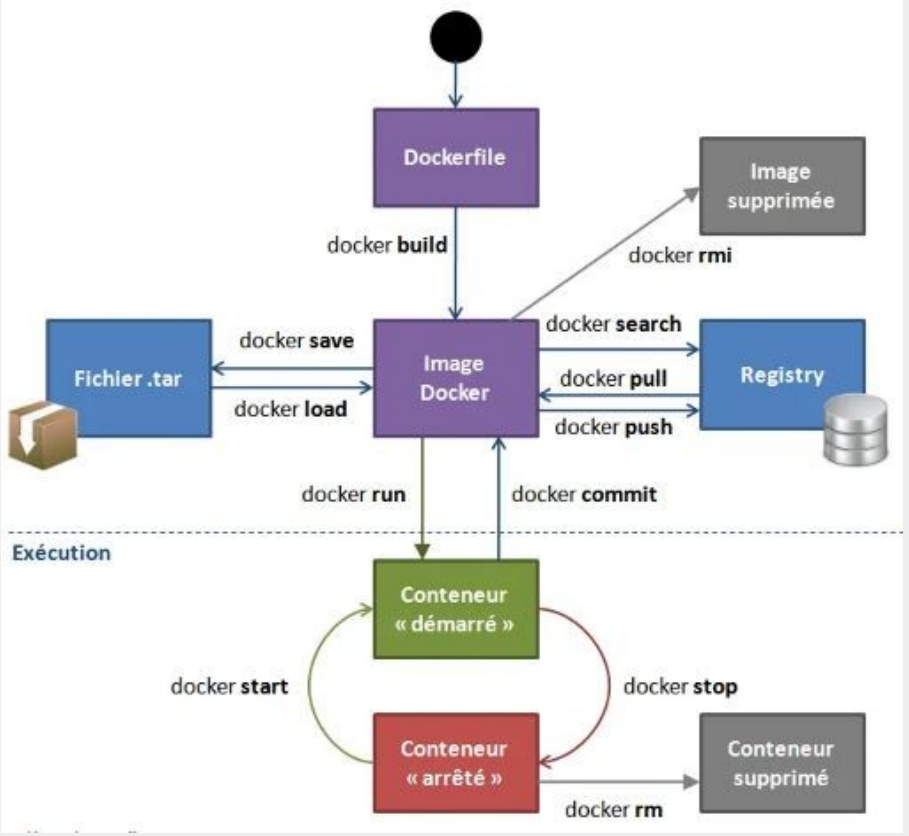

Premiers pas

- Détail du **docker run**
  - Création d'un conteneur à partir d'une image avec des **namespaces et des cgroups**

    => puis, exécution d'une commande programmée **dans l'image sous jacente**

    => le processus associé est **isolé** du reste du host par les namespaces…
  - Si le processus s'arrête normalement ou en erreur, dans tous les cas le conteneur est stoppé
  - On peut le (re)démarrer avec **docker (re)start**
  - On peut également, ajouter un autre processus dans le même conteneurs (i.e dans les namespaces)

    => avec **docker exec <ctn> <cmd>**

  - Par conséquent, un conteneur est vivant s'il contient un processus vivant :

    - un **conteneur « one shot »** exécute un processus **éphémère** qui doit modifier l'état du host d'un autre conteneur à travers le réseau ou le stockage (volumes)

    - **un conteneur « permanent »** exécute un processus de type **« daemon », un serveur** qui ne retourne pas

Premiers pas

- Détail du **docker run : effet sur le namespace PID**
  - Les namespaces sont des structures imbriquées
  - Il ya toujours un namespace parent
  - Le namespace root est celui du host lui même
  - Un processus dans un ns a **toujours** un pid et aussi dans son **ns parent**
  - Par contre on peut ajouter le processus appelant dans le namespace enfant ou pas selon que la commande **unshare** utilise l'option **--fork**

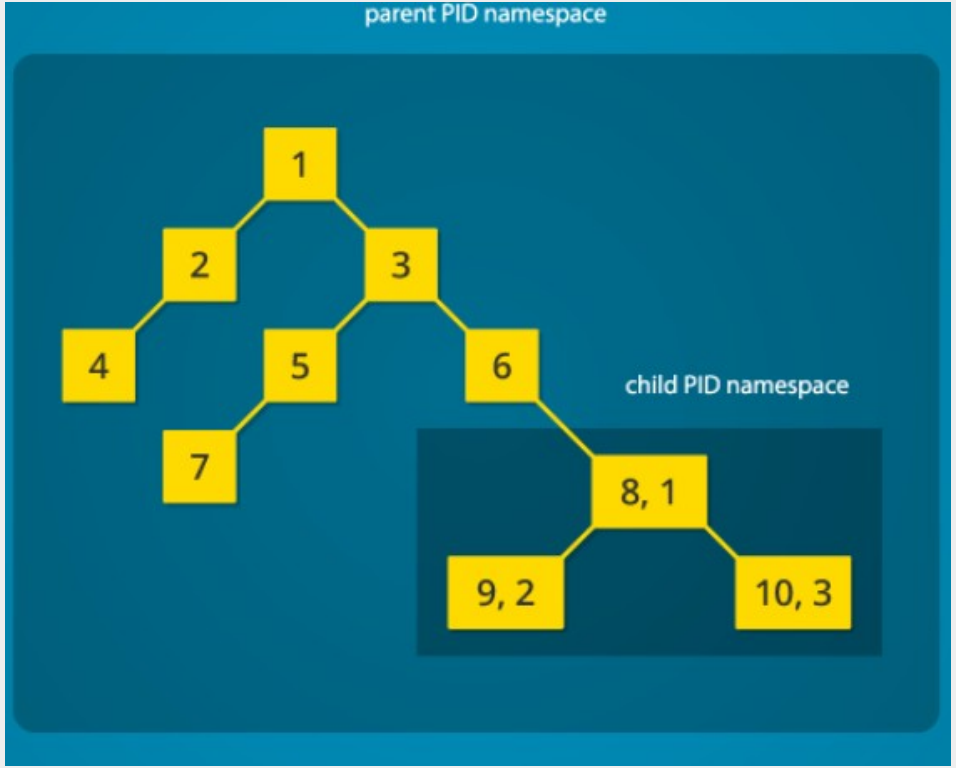

Premiers pas

- Introspection
  - Voir la liste des conteneurs en exécution : **docker ps**
  - Voir la liste des conteneurs créés : **docker ps -a**
  - Filtrer la liste : **docker ps -f key=value** (id, name, status)
  - Liste d'identifiants (placer en entrée d'une commande): $(docker ps -a -q)

  - Afficher les informations disponibles sur un conteneur : **docker inspect**
  - Afficher seulement certaines informations : docker inspect --format **"Go template : {{ .Name }}"**

Premiers pas

- Format « GO template »
  - Technique de requêter « parser » des données,
    - en particulier les obkets json utilisés par Docker

```
# afficher un ou des champs
docker inspect --format "{{.Id}} {{.State.Status}}"

# afficher un objet ou une liste en json
        //  --format "{{json .State}}"

#       //     avec des champs séparés
        //   --format "{{join .State ' , ' }}"

# similaire à docker
(echo "ID NAME STATUS"; docker inspect $(docker
ps -q) --format '{{printf "%.10s" .Id}} {{.Name}}
{{upper .State.Status}}') | column -t -s ' '
```

Premiers pas

- Options principales d'exécution (docker run)
  - **--name** : nom du conteneur, plus compréhensible que l'id
  - **--restart** : condition de redémarrage si un erreur survient (**always**, **unless-stopped**)
  - Redirection des commandes exécutées dans les conteneurs sur la sortie « **stdout** »
  - **--rm** : le conteneur est supprimé quand il est stoppé
  - **-e VAR=value** ; créer / mettre à jour une variable d'environnement dans le conteneur
  - **--env-file <path>** : injecter les variables du fichier en paramètre dans le conteneur

Premiers pas

- Conditions d'exécution (docker run | exec)
  - **-i** : ajout d'un flux d'entrée « **stdin** » pour exécuter des commandes dans le conteneur
  - **-t** : ajout d'un driver « **pseudo-tty** » pour bénéficier des propriétés d'un terminal
  - **-it** : **Mode interactif**. Une fois lancé :
    - **Ctrl + P + Q** : revenir sur le shell de l'hôte sans interrompre le terminal conteneur, **docker attach** pour revenir
    - **exit** pour interrompre le terminal conteneur et revenir au shell de l'hôte
  - **-d** : **Mode détaché**, lancer le conteneur en arrière plan
    - sans flux d'entrées / sorties
    - le conteneur s'arrête en même temps que son processus interne
  - En mode détaché, on affiche la trace du processus du conteneur avec **docker logs**

RESEAU

- Le namespace « network » et les drivers réseau
  - Ce namespace du noyau Linux permet d'obtenir une copie logique (virtuelle) de la pile réseau de l'hôte, en la configurant spécifiquement pour un conteneur. Cela inclus :

    - l'utilisation d'interfaces réseaux, adresses et tables de routages spécifiques

    - des règles de Firewall spécifiques

  - Les drivers réseau de docker permettent de spécifier le type d'interfaces réseau à mettre à disposition des conteneurs

    - **driver bridge : par défaut**, réseau virtuel permettant à des conteneurs de communiquer entre eux sur une machine (un démon docker)

    - driver host : utilisation directe d'une interface réseau de l'hôte pour un conteneur

    - driver none : pas de couche réseau, le conteneur ne communique pas

    - **driver overlay : pour un cluster swarm** (cf infra) : agrège les réseaux associés à plusieurs démons docker (machines sur un lan ou un wan)

RESEAU

- Liaisons entre conteneur : --link pour le réseau par défaut « docker0 »
  - Pour faire communiquer plusieurs conteneurs sur docker0 on peut passer :
    - par les ips, peu pratique car on ne peut pas toujours prévoir ces ips (**--ip <ip_address>** pour une ip fixe)
    - par un alias réseau via l'option **--link <ID | Name | Name : Alias >**
  - Dans les faits, on préférera utiliser un **réseau créé par l'utilisateur** (cf infra)

```
# lien entre le conteneur courant et un conteneur ctn
docker run … --link ctn:alias
```

RESEAU

- Liaisons entre conteneurs : réseaux créés par l' utilisateur
  - L'utilitaire **docker network** permet de créer des réseaux virtuels pour faire communiquer les conteneurs
  - Lister : **docker network ls**
  - Créer

```
# options avec les valeurs par défaut
docker network create
--driver=bridge
--subnet=172.18.0.0/16
--gateway=172.18.0.1
my_network_name
```

  - Inspecter : **docker network inspect**
  - **Sur ces réseaux, le nom des conteneurs est un alias réseau (hostname) par défaut**

RESEAU

- réseaux créés par l’ utilisateur : ajouts de conteneurs
  - Création

```
docker run …  --network my_network_name
```

  - Pour un conteneur déjà créé

```
docker network connect my_network_name ctn_name
```

  - Pour déconnecter : **docker network disconnect**
  - Supprimer un ou des réseaux vides de conteneur : **docker network rm <networks>**
  - Supprimer tous les réseaux non utilisés : **docker network prune**

RESEAU

- Publication de ports (-p | --publish)
  - L'installation de docker comprend la création d'une interface réseau virtuelle « **docker0** » de type bridge en **172.17.0.1/16**
  - Par défaut, un conteneur est créé avec une ip allouée sur ce réseau. Les ports réseaux du conteneur ne sortent pas
  - **Publier** un port, c'est rediriger un port de l'interface docker sur une interface de l'hôte

```
# interface:port_externe:port_interne
docker run … -p 192.168.2.1:8080:80
# toutes les interfaces, choix de port, couche transport
-p 8080-8090:80/tcp
# publier tous les ports internes sur des ports > 32768
-P | --publish-all
```

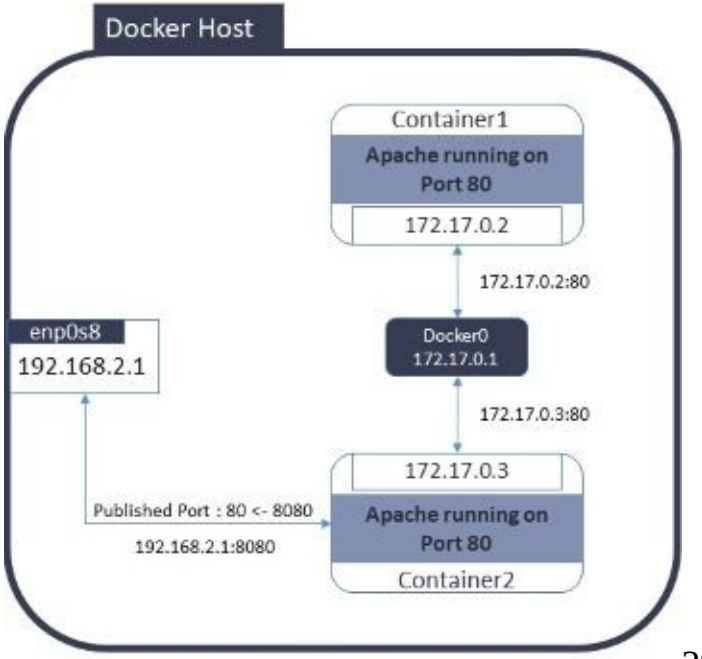

STOCKAGE

- Copier des fichiers / dossiers entre l'hôte et un conteneur

```
# copie sur le conteneur
docker cp <src_path> CTN :<dest_path>

# copie depuis le conteneur
docker cp CTN :<src_path> <dest_path>
```

- Sur le conteneur, le répertoire d'accueil est la racine **/**
- docker cp produit un flux tar, on peut le rediriger sur stdout avec
- Le fichier destination n'est pas le fichier source (!= inode)

```
docker cp CTN:<src_path> - | tar x -O
```

STOCKAGE

- Persistance des données dans les conteneurs
  - Toutes les données à l'intérieur d'un conteneur sont supprimées avec le conteneur
  - Les **volumes** de données permettent de partager des données entre l'hôte et les conteneurs

    - **bind mounts** : partage entre un **dossier utilisateur** et un dossier dans un ou plusieurs conteneurs

    - **volumes nommés** : partage entre un **dossier géré par docker** et un dossier dans un ou plusieurs conteneurs

    - **tmpfs** : partage temporaire enregistré en RAM, non partageable entre conteneurs

  - De fait, les données partagées existent toujours sur l'hôte

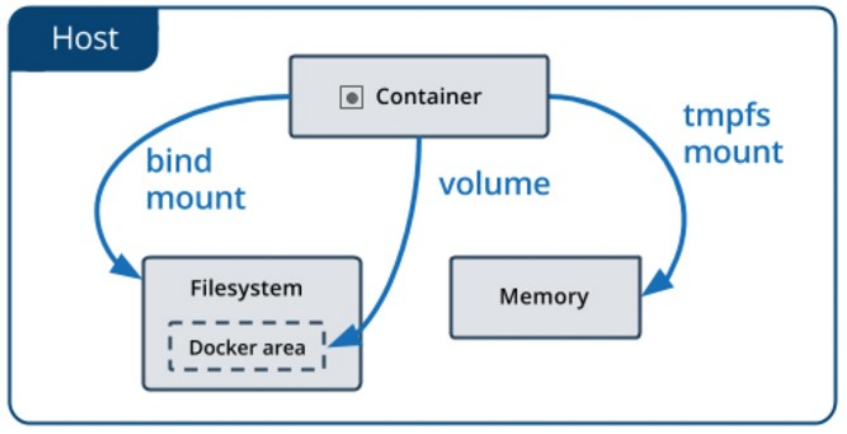

STOCKAGE

- Drivers de stockage
  - Par défaut, docker utilise le driver local **overlay2**, qui enregistre les volumes sur l'hôte en utilisant le système de fichiers **overlayFS du noyau linux > 3.18**

```
docker info
```

  - On peut spécifier d'autres systèmes de fichiers (tmpfs => RAM, sshfs => machine distante, nfs => partage NFS, CIFS => partage samba …)
  - Les volumes docker pilotent en réalité la commande linux **mount**, d'une manière ou d'une autre

STOCKAGE

- docker run --mount vs -v
  - L'option **-v** permet de spécifier rapidement une correspondance entre un élément de l'hôte et sa contrepartie sur le conteneur, ainsi que des options de montage

```
# bind mount
docker run … -v path/to/bind_mount:/path/on/container:opt1,opt2,…
# volume nommé
docker run … -v volume_name:/path/on/container:ro…
```

  - L'option **--mount** permet la même chose, avec une interface plus complète, notamment le règlage d'un **driver spécifique via les paramètres volume-opt**

```
# bind mount
docker run … --mount src=path/to/bind_mount,dst=/path/on/container,readonly
# volume nommé
docker run … --mount src=volume_name,dst=/path/on/container,volume-
driver=local,volume-opt=type=nfs...
```

STOCKAGE

- Création de volumes nommés

```
docker volume create <volume_name>
--driver local -o opt1=val1 -o opt2=val2

docker volume inspect <volume_name>
docker volume ls
```

```
# suppression de volume non lié à un conteneur en exécution
docker volume rm <volume_name> | ID

# suppression des volumes non utilisés
docker volume prune
```

DOCKER COMPOSE

- Infrastructure as Code :
  - Piloter les commandes docker

    depuis un **ficher de configuration** au format **YAML**

  - Gérer en ligne de commande plusieurs conteneurs

    comme un ensemble de services inter-connectés

    => **microservices**

  - Disponible comme plugin docker

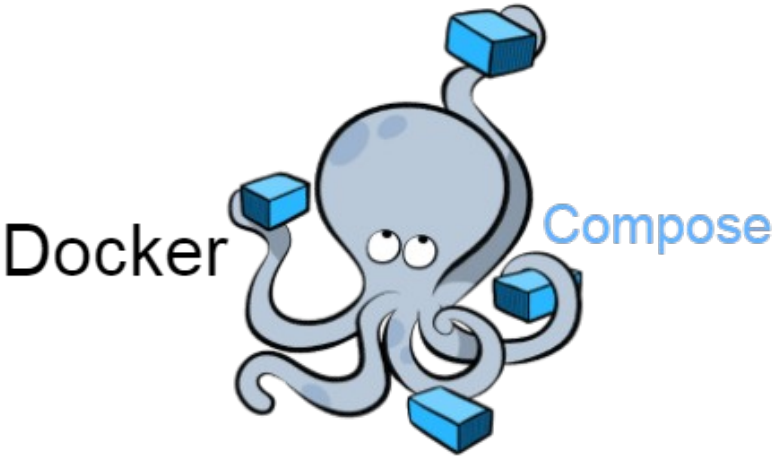


```
sudo apt-get install docker-compose-plugin
```

DOCKER COMPOSE

- Le format YAML :
  - format de représentation de données par **sérialisation**, conçu pour être aisément modifiable et lisible
  - Dérivé de la représentation d'un objet **JSON déplié**

```
{                                                    ---
   "key" : "value",                                  key: value
   "other key" : "other value",          =>          other key: other value
   "num" : "3.14"                                    num: 3.14
   "bool" : "false",                                 bool: false
   "none" : "null"                                    none: null
}                                                    "with quotes": "possible"
```

DOCKER COMPOSE

- Le format YAML : imbrications
  - Par rapport à JSON :

    - les objets { ... } sont remplacés par une **indentation** de 2 ou 4 caractères

    - les listes [...] sont remplacés par une indentation de 2 ou 4 caractères préfixée par « **- [espace]** »

    - YAML accepte les listes et objets **JSON** comme valeur de clés

```
{                                       ---
   "object" : {                         object:
      "key" : "value",          =>          key: value
      "items" : [                          items:
         "item1",                             - item1
         { "k1": "v1", "k2": ... },           - k1: v1
         …                                      k2: v2
         "item3"                              - item3
      ]
}
```

DOCKER COMPOSE

- Correspondances clé / option commandes docker (run, build, network, volume, ...)

```
services:                          # service = app conteneurisée
  app:                             # nom du service (arbitraire)
    container_name:                # --name
    image:                         # nom de l'image
    build:                         # docker build d'un Dockerfile
      context: .                   # chemin du Dockerfile
      args: [...]                  # --build-arg
    restart:                       # --restart
    depends_on:                    # dépendance à des services (qui doivent exister !)
    env_file:  [...]               # fichier de variables d'environnement
    environment:                   # variables directement dans le document
      - VAR=${PARAM:default} # valeurs par défaut
    ports: [8080:80]               # EXT_PORT:INT_PORT ou PORT seul pour exposition
    volumes:                       #
      - type: bind                 # --mount
        source: .
        target: /
      - /src:/dev:opts             # -v
    networks: [...]                # --net
```

DOCKER COMPOSE

- Commandes docker compose principales
  - docker compose **up -d** : lancement de la stack (conteneur) dans l'ordre et en mode détaché
  - docker compose **down -v** : stopper les conteneur et les réseaux et détacher les volumes
  - docker compose **rm -f** : supprimer les conteneurs si stoppés
  - docker compose **run, exec <ctn name> <cmd>** : lancer un service standalone avec une commande
  - docker compose **logs, ps** : versions agrégées des commandes docker

DOCKER COMPOSE

- Utilisation des profiles
  - La clé **« profiles »** présente une liste d'éléments arbitraires
  - Permettent de sélectionne un série de services qui fonctionnent ensemble

```
...
profiles :          docker compose --profile profile1 (up, down, ...)
  - profile1
  - profile2
```

- Utilisation des labels
  - La clé **« labels »** présente une liste d'éléments arbitraires
  - Permettent de filtrer un service dans docker ps de façon analogue avec les LABELS du Dockerfile
  - Mais aussi en utilisant les valeurs des labels dans les conteneurs (ex : de l'image **traefik**)

CREER DES IMAGES

- Retransformer un conteneur en images: docker commit
  - On peut **enregistrer l'état d'un conteneur** lancé avec des modifications en tant qu'image
  - Afficher les modifications depuis le lancement

```
docker diff <ctn ID | ctn name >
```

  - docker commit met le conteneur en pause pour éviter d'enregistrer un état instable et recréé une image à partir de cet état du conteneur

```
docker commit <ctn ID | ctn name > <image name>:<tag>
# métadonnées du commit
-a <author> -m <message>
```

  - Le commit ne tient pas compte des données partagées dans des **volumes**

CREER DES IMAGES

- Le fichier Dockerfile
  - Contient des **directives**
  - Qui modifient l'état d'une image de base
  - De multiples façon :
    - exécution de commandes
    - injection de fichiers / dossier
    - changement d'utilisateur / répertoire home
    - port réseau exposé sur l'interface docker
    - commandes à exécuter au lancement du conteneur
    - ...

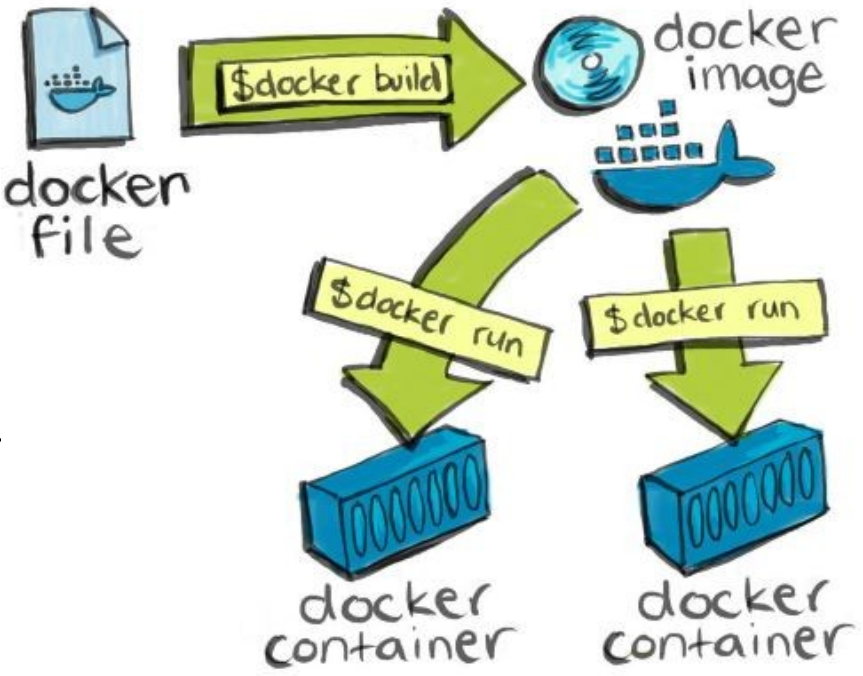

CREER DES IMAGES

- Dockerfile : principales directives
  - **FROM <image>:<tag>** : image et tag de base
  - **LABEL <key> <value>** : métadonnées de l'image (permet de filtrer les images)
  - **COPY [--option] <src> <dest>** : copie des éléments de l'hôte dans l'image
    - utilisation de wildcards (*, ?) pour les éléments source
    - possibilité de changer le propriétaire des éléments sur l'image (--chown)
  - **ADD [--option] <src> <dest>** : comme COPY mais gestion de protocoles réseaux pour la source
  - **RUN <cmd>** : exécute une commande
  - **USER <user[:group]>** : règle l'utilisateur par défaut dans l'image
  - **WORKDIR <path>** : répertoire home par défaut de l'image
  - **EXPOSE <ports>** : déclare les ports réseau sur lesquels le service installé sur l'image écoute
  - **VOLUME <paths>** : création de volumes persistant les chemins renseignés
  - **ENTRYPOINT <cmd>** : commande automatiquement lancée avec un conteneur de cette image
  - **CMD <cmd>** : termine et dynamise l'ENTRYPOINT, remplaçable par le paramètre de docker run

CREER DES IMAGES

- Mécanisme du build d'image
  - Docker build créé l'image à partir du Dockerfile et du **contexte de build**
    - çàd le répertoire contenant ce dernier (en local ou dans une archive ou dans un dépôt git distant)

```
docker build -t <image : tag> path/to/context
```

  - Le fichier **.dockerignore** permet de ne pas considérer les éléments qu'il contient dans le contexte
    - éléments indisponibles pour les directives COPY et ADD
    - car le contexte est chargé côté démon docker => bande passante
  - On peut construire une image sans contexte

```
docker build -t <image : tag> - < /path/to/Dockerfile
```

CREER DES IMAGES

- Paramétrer un build
  - La directive **ENV** permet de déclarer ou initialiser des variables d'environnement dans l'image

```
ENV VAR
ENV VAR=default
```

  - Ces variables peuvent être modifiées au lancement du conteneur

    - docker run … -e VAR=some_value

  - La directive **ARG** permet de déclarer des variables initialisées au moment du build

```
ARG PARAM
...
docker build -t <image : tag> --build-arg PARAM=val
```

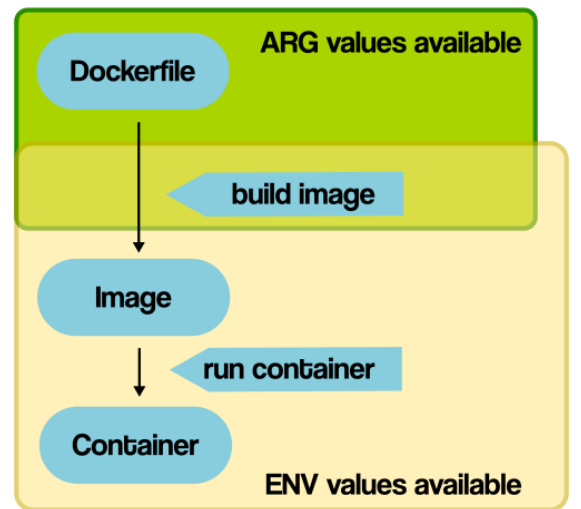

CREER DES IMAGES

- Tester un build
  - La directive **HEALTHCHECK** permet d'exécuter une commande au moment du docker run

```
HEALTHCHECK --interval=1s --timeout=30s --retries=30 --start-period=0 CMD <cmd>
```

  - Cette commande doit **démontrer** que le service dans le conteneur s'est lancé convenablement
  - À l'issue du lancement, un réponse positive du HEALTHCHECK ajoute la valeur « **(healthy)** » au **statut du conteneur** dans la sortie de **docker ps**

CREER DES IMAGES

- Le « multistaging » build
  - On peut utilise plusieurs **Directives FROM** comme des étapes de construction ou **stage**

```
FROM <image> :<tag> AS <stage_name>
```

  - On peut travailler dans cette(s) image(s) auxilliaire(s) (RUN, COPY, ADD, ….)

  - Le but est d'injecter des éléments dans une image amont et surtout **la dernière qui sera buildée**

```
COPY --from=<stage_name> [stage_path_src] [build_image_dest]
```

CREER DES IMAGES

- Composition d'une image
  - Chaque directive du Dockerfile

    créé une couche de système de fichier **en lecture seule**
  - Le conteneur rajoute une **fine couche en lecture écriture**
  - Les conteneurs **partagent** les couches communes en lecture seule

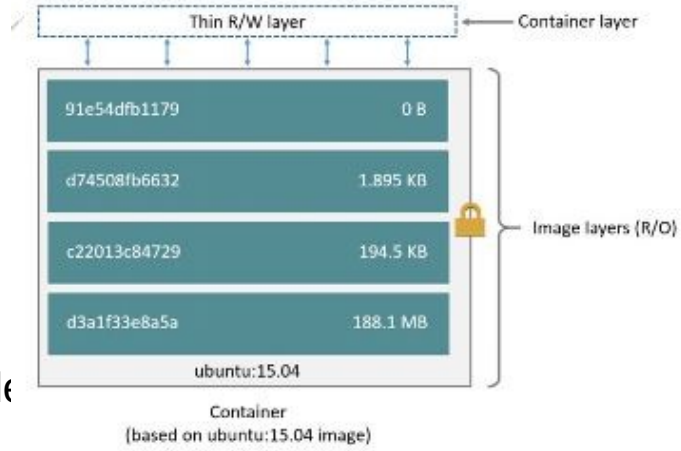


```
# size : taille de la couche RW
# virtual size : taille RW + RO (mutualisées)
docker ps -s
```

- On peut utiliser **au maximum 127 couches** par image

CREER DES IMAGES

- Mécanisme « Copy on Write » CoW d'overlayFS
  - stratégie de partage et de copie de fichiers pour une efficacité maximale.
  - Si un élément existant dans une couche inférieure de l'image est utilisé **en lecture** par une autre couche (y compris la couche conteneur) doit y accéder en lecture, **il n'est pas copié**.
  - Le même élément, **modifié** par une autre couche est **copié** sur cette couche et utilisé par les autres couches depuis cette nouvelle couche

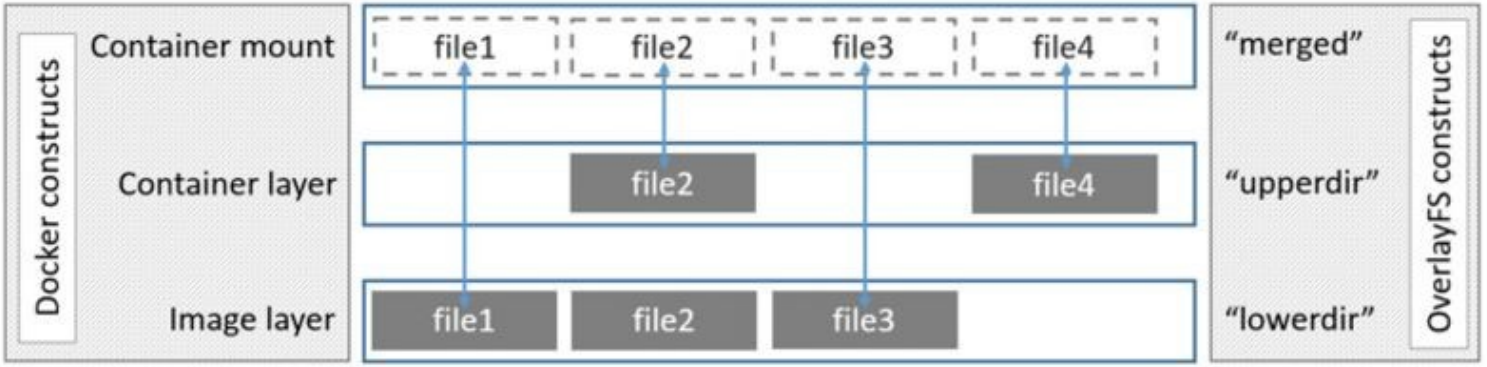

CREER DES IMAGES

- Bonnes pratiques
  - Les couches doivent être ajoutées par **fréquence de mise à jour croissante**
  - Puisqu'on ne peut réutiliser une couche que si les couches parentes n'ont pas changé
  - Minimiser le nombre de couches est aussi plus performant

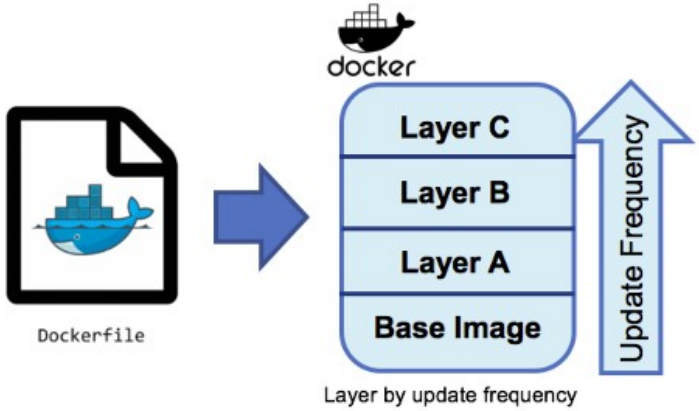


```
# 2 couches
RUN cmd1
RUN cmd2
```

```
# 1 couche
RUN cmd1 && \
    cmd2
```

  - En particulier, les directives **RUN** qui créé qqch et supprime ce qqch doivent être chaînée
  - Sinon la première (qui créé) est toujours là en dessous de celle (qui supprime)
  - Les builds en erreur créent des « **dangling images** » qu'on supprime avec **docker image prune**

CGROUPS

- Définition
  - Les Cgroups forment une fonctionnalité du **noyau Linux** qui gère les modalités d'**accès aux ressources système** (RAM, CPU, I/O, Network) pour des ensembles de processus donnés
  - Les Cgroups sont organisés en **hierarchies**, avec héritage de propriétés d'un Cgroup parent
  - Chaque Cgroup définit les **sous systèmes** sur lequels il désire réguler l'accès
    - **blkio** : entrées / sortie sur les stockages en mode bloc
    - **memory** : accès RAM
    - **cpu** : % de temps CPU global
    - **cpuset** : sélection spécifique de cpus
    - **net_cls** : gestion des paquets réseau distingués par un identifiant de classe
    - **pids** : gestion du nombre max de process exécutables
  - **/sys/fs/cgroup**
  - Docker créé un **cgroup spécifique** à la création d'un conteneur

```
docker stats
```

CGROUPS

- Limiter la mémoire (docker run)
  - On utilise les options
    - **--memory** ou **-m** pour limiter la quantité de ram max autorisée hors SWAP
    - **--memory-swap** pour la même chose SWAP inclus
    - **« memory == memory-swap » ⇒ pas de Swap**
  - Si le processus dans le conteneur essaie d'allouer plus de RAM qu'autorisé, le **processus est tué** et le conteneur stoppé (sauf avec **--oom-kill-disable**)
  - **--memory-reservation** fixe une limite basse en cas de conflits d'accès à la RAM **entre conteneurs**
  - Attention, la RAM autorisée n'est pas la RAM disponible ! Par ex. la commande **free** ne donne pas la bonne valeur
  - Voir dans le conteneur

```
cat /sys/fs/cgroup/memory/memory.limit_in_bytes
```

CGROUPS

- Limiter l’accès aux cpus (docker run)
  - **--cpus** : valeur nominale à rapporter au nb total de CPUs disponibles
    - ex : --cpus=’1.5’, pour 2 cpus ⇒ 75 %
  - **--cpuset-cpus : sélection de CPUs autorisés pour le conteneur**
    - **numérotés à partir de 0 : --cpuset-cpus=0,3**
    - sélectionner une gamme : **--cpuset-cpus=0-3**
  - On peut accéder à ces métriques via l’utilitaire **htop** lancé sur l’hôte

CGROUPS

- Limiter les débits d'entrées / sorties (docker run)
  - Il faut d'abord trouver le device sur lequel est monté le conteneur (**/dev/sda** par défaut sur Ubuntu par exemple)

    - **df -h, docker inspect <CTN ID | Name> | grep Device**

  - **--device-read-bps et --device-write-bps** :

    - --device-read-bps /dev/sda:1mb

  - On peut accéder à ces métriques via l'utilitaire **iotop** lancé sur l'hôte

CGROUPS

- Tester les Limites
  - Utiliser l'image **polinux/stress**
  - **docker exec -it <ID> stress -h**
  - **https://hub.docker.com/r/polinux/stress-ng**

SECURITE DES CONTENEURS

- Le namespace User
  - Même si l'on ajoute l'utilisateur non root dans le **groupe docker** pour utiliser la cli sans sudo,

    => les conteneurs (processus) sont créés avec root.
  - Pour utiliser le démon doker (dokerd) sans être root , on doit appliquer une procédure avancée

    => **le mode ROOTLESS**
  - Dans tous les cas, à la création d'un conteneur, un **namespace user** est créé

    => qui va donner l'impression au processus d'être lancé en tant que root (uid = 0)
  - On peut voir le mapping de l'utilisateur dans le conteneur dans le fichier **/proc/[PID]/uid_map**

```
[uid dans le ctn] 0 --------- [uid dans le host] 0 ---------- [nb de mappings possibles]
```

  - Le uid 0 dans le conteneur peut **outrepasser les permissions et les propriétés** des fichiers,

    => Mais même dans le cas 0 => 0, le root à l'intérieur n'a pas **les mêmes capacités**

SECURITE DES CONTENEURS

- Les Capacités Linux
  - Ensembles de permissions associées aux processus et / ou aux fichiers
  - On peut voir la totalité des 39 capacité en Linux **ICI**
  - On peut voir les 14 capacités **ICI** permises a priori dans les conteneur (en négatif les interdictions)
  - On peut voir les capacités liées à un processus lancé en root dans le conteneur

    => ou la même chose lancé en root dans le host dans **/proc/[PID]/status | grep Cap**

    uid 0 dans un ctn

```
CapInh: 0000000000000000
CapPrm: 00000000a80425fa
CapEff: 00000000a80425fa
```

    uid 0 dans le host

```
CapInh: 0000000000000000
CapPrm: 0000003fffffffff
CapEff: 0000003fffffffff
```

  - On peut ajouter ou enlever des capacités au processus (donc le conteneur) avec les options

    => **--cap-add** ou **--cap-drop**

SECURITE DES CONTENEURS

- Le filtre seccomp
  - Ensembles de permissions associées aux appels système en C utilisés en dans l'espace noyau
  - Il ya 380 appels système Linux
  - Docker utiliser un **profile JSON** par défaut de (des)activations d'appels associés aux **capacités**

    docker run --security-opt seccomp=/path/to/profile.json

```
{
   "names": [
       "mount",
   ],
  "action": "SCMP_ACT_ALLOW" ( OU  "SCMP_ACT_ERRNO" ) # oui ou non
      "includes": {   ( OU "excludes" )  # si capacité activée ou non )
          "caps": [
              "CAP_SYS_ADMIN"
          ]
      }
}
```

REGISTRE DOCKER

- L'image registry
  - Le dépôt public **docker hub** est installé par docker
  - Avec l'image **registry:2**
  - On peut installer son propre registre d'images privées grâce à cette image
  - Pour échanger des images avec le registre, on utilise les commandes docker suivantes
    - docker **pull**
    - docker **login -u** [uname] **-p** [passwd]
    - docker **tag** (ou docker build)
    - docker **push nom_de_domaine:port/espace_de_nom/image:tag**